

新聞文章情緒偵測



1. 專案概述

目標：訓練一個能自動判斷財經新聞情緒（正向／中立／負向）的分類模型，並驗證情緒指標與股市表現的相關性

資料來源：<https://www.kaggle.com/datasets/ankurzing/sentiment-analysis-for-financial-news?resource=download>


核心產出：BERT 情緒分類模型、S&P 500 情緒與股價相關性分析



2. 模型開發

2.1 EDA


情緒分布不平衡




資料集中中立新聞佔最大宗（約 59.4%），正向約 28.1%，負向約 12.5%。這反映財經新聞以客觀事實陳述為主，帶有強烈情緒色彩的報導相對少數。不平衡分布驗證了資料切分時採用 Stratified Split 的必要性。

關鍵字分析

初步 Wordcloud 發現 mn、finnish、eur 等詞彙出現頻率極高，但這些詞僅為單位或國家背景，對情緒判斷無貢獻，因此將其定義為停用詞（Stopwords）移除，使核心財經詞彙得以浮現。





長條圖分析主要發現：

- Profit、Sales、Net 在正負向新聞中均為高頻詞
- 正向新聞核心動詞為 rose、increased、up；負向為 decreased、fell、loss
- Said 在正向新聞中高居頻率第一，出現次數顯著多於負向新聞，反映企業表現佳時發言人傾向主動發聲，面臨虧損時新聞則以客觀數據陳述為主

2.2 模型架構

Baseline：TF-IDF + Logistic Regression

- TF-IDF 僅考量詞頻與關鍵字特徵，無法理解詞序與語境，以此作為基準，用於對比 BERT 在處理複雜語義時的優勢。

核心模型：BERT (bert-base-uncased)


元件	設計說明
分類層	將 768 維特徵壓縮至 3 維輸出
輸出	Softmax 轉換為三類信心機率，取最高者為預測結果
Learning Rate	2e-5，採低學習率避免破壞預訓練權重
Batch Size	16

元件	設計說明
Epochs	2，參考原始論文建議，小型資料集 2 輪微調即可有效提取特徵並防止 Overfitting

2.3 評估結果

模型	準確率
Baseline (TF-IDF + LR)	71.44%
BERT	84.23% (+12.79%)

BERT 較 Baseline 提升約 13%，後續市場分析均採用 BERT 模型進行預測。



混淆矩陣關鍵發現：

- 極性區分能力強：模型幾乎不會將負向新聞誤判為正向，正負向邊界清晰
- 主要預測誤差集中在「中立」與其他兩類的邊界，原因是許多財經新聞僅陳述事實（如「營收成長 1%」），人類標注者本身也難以明確界定中立或微幅正向

- 不平衡資料處理有效：雖然中立類佔訓練資料近 60%，模型在極性類別的區分準確度仍高，未出現偏祖大宗類別的預測偏誤



3. 實際應用：Yahoo Finance 情緒與市場表現比較

3.1 實作流程

資料蒐集：

- 選取 S&P 500 權重最高的前 100 大成分股作為市場觀測標的
- 以 yfinance 爬取各成分股近期新聞標題，蒐集 2025/11/04–2025/12/24 共 812 筆
- 資料過濾後聚焦於新聞量最密集的 12/16–12/24（有效樣本 763 筆）

分析設計：

- 每日平均情緒：計算當日所有新聞情緒分數平均值，反映市場即時情緒總和
- 時間平移（Shift +1 Day）：將情緒指標往前平移一天，檢驗「昨日（T-1）新聞情緒」是否能預測「今日（T）股價走勢」，模擬真實交易情境
- 統計量化：相關係數、p-value 檢定


3.2 結果

相關性彙整表：

分析對象	相關係數	解讀
當日情緒 vs. 股價點數	+0.6115	趨勢同步：情緒能有效反映市場價格走勢
昨日情緒 vs. 股價點數	+0.2364	關聯轉弱：價格點數主要受當下情緒影響
當日情緒 vs. 日報酬率	-0.0983	無顯著關聯：日報酬受隨機雜訊干擾大

分析對象	相關係數	解讀
昨日情緒 vs. 日報酬率	-0.6104	領先預警：昨日極端情緒對今日報酬具反向預測效力

情緒指標有效反映市場 ($r = +0.6115$)



- 當日情緒平均分數與 S&P 500 股價點數呈正相關，趨勢走勢契合。特別是 12/17，模型捕捉到市場負面情緒，當日指數同步觸及波段低點，驗證 BERT 能準確識別市場情緒底點。

反向預測領先訊號 ($r = -0.6104$)

將情緒指標往前平移一天後，與隔日報酬率呈現顯著負相關。當昨日新聞情緒出現極度悲觀（如 12/17）時，預示市場已過度反應，進而引發次日抄底反彈（12/18 出現正報酬）。

相較於當日情緒對報酬率的低相關性 ($r = -0.09$)，T-1 平移結果顯示新聞情緒對股價報酬率變動具備約 1 個交易日的滯後反應，賦予情緒指標在極短線操作上的預警價值。此結果與金融學中的**情緒過度反應假說**一致。

⚠️ 統計限制：高密度樣本觀測期間僅 7 個交易日 ($N=7$)，p-value 未達傳統顯著門檻 (0.05)。然而相關係數絕對值達 0.61，結合視覺化的波段轉折對應，在短期市場情緒監測與極端情緒辨識上具備實務參考價值，後續可延長觀測期間以驗證結果穩健性。



4. 挑戰與學到的事

1. 不平衡資料的處理

中立類別佔近 60%，若不處理可能導致模型偏向預測中立。透過 Stratified Split 確保各類別比例一致，並從混淆矩陣驗證模型未出現偏祖問題。

2. 中立邊界的模糊性

財經新聞的「中立」與「微幅正向」本身就難以區分，這是任務本身的固有難度，而非模型設計缺陷。混淆矩陣的誤差分布印證了這個判斷。

3. 低學習率的重要性

BERT 為預訓練模型，使用過高學習率會破壞原有權重。採用 $2e-5$ 進行微調，在保留預訓練語言知識的前提下完成下游任務適應。

4. 情緒指標的非直覺性

最初預期情緒與報酬率應呈正相關，實驗結果卻顯示 T-1 負相關才是更強的訊號。這提醒了「市場已 price in 的情緒反而會反轉」，數據結果有時會挑戰直覺假設。

參考資料：BERT 原始論文 *Devlin, J., et al. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.*