

1. 專案說明

專案程式碼與實作細節請參考 GitHub:

<https://github.com/Candice251/Market-Sentiment-Analysis/tree/main>

1.1 設計考量點

- 選用 BERT 模型: 傳統關鍵字比對法 (如: 看到 "Loss" 即判斷為負向) 難以處理複雜句式, BERT 模型具備語境理解能力, 能判斷新聞標題是屬於「負面衝擊」或是「客觀陳述事實」, 提升情緒分類的準確度。
- 鎖定權重前 100 大公司: 透過觀測 S&P 500 中市值最高的 100 家企業, 能建立具備市場代表性的情緒樣本, 避免個別小型公司的零星消息干擾大盤情緒的判斷。
- Yahoo Finance 資料過濾: 考量資料抓取的完整度, 捨棄了數據較稀疏的前期資料, 聚焦於新聞量最密集的區間 (12/16 - 12/24), 確保每日平均情緒是由足夠的樣本支撐, 不會被一兩則零星新聞影響。
- 嘗試「平移一天」分析: 除同步對照外, 為了測試新聞是否有預測功能, 嘗試將市場情緒分數往前平移一天, 測試「昨天的情緒」跟「今天的股價」是否有關連, 而不只是看當天發生了什麼。

1.2 未來可優化方向

- 擴大樣本規模與觀測週期: 目前受限於高密度新聞資料僅有 7 天, 導致相關性檢定的 p-value 較難達到統計顯著水準。未來若能採集一整季甚至半年的歷史新聞, 將能進行更長期的分析, 提升統計結果的準確性。
- 加入指標分析: 除了情緒指標外, 未來可嘗試加入成交量或波動率等數據進行分析, 建立更全面的市場預測模型。
- 自動化抓取系統: 目前資料採集與日期過濾仍需人工介入, 未來可優化為自動化資料抓取, 定時抓取、即時預測並自動更新情緒趨勢圖表。

2. 建模操作細節 & 結果

2.1 資料準備與前處理

1. 資料來源: Kaggle Financial News Sentiment Dataset。


2. 前處理:

- 去除標點符號與特殊數字以及 URL 與 HTML 標籤
- 停用詞處理: 在訓練階段保留所有停用詞 (如 not, but), 以維持句法結構供 BERT 理解; 但在視覺化階段採用迭代式過濾, 移除 EUR, mn (million) 等無情緒意義的單位詞, 以凸顯核心財經詞彙。
- 資料分割: 採用 80% 訓練集、20% 測試集, 並透過 Stratified Split 確保各情緒類別分佈均勻。

2.2 EDA



1. 情緒分佈不平衡

- 觀察：資料集顯示中立新聞佔最大宗 (約 59.4%)，其次為正向 (約 28.1%)，最少為負向 (約12.5%)。
- 解讀：這反映了真實財經新聞的特性，大部分報導屬於客觀的事實陳述，帶有強烈情緒色彩的新聞相對較少。這也驗證了在資料分割時使用 Stratified Split 的必要性。



2. 關鍵字分析

- Wordcloud
 - 在初步的 Wordcloud 分析中，發現 mn (million)、finnish、eur 等詞彙出現頻率極高，考量這些詞彙僅為單位或特定國家背景，對於情緒判斷不具顯著貢獻，因此將其定義為停用詞 (Stopwords) 並移除，成功大幅降低視覺化雜訊，使真正的核心財經詞彙得以浮現。
- 長條圖：
 - Profit、Sales、Net 在正負向新聞中均為高頻詞。
 - 正向新聞: 核心動詞為 rose、increased、up。
 - 負向新聞: 核心動詞為 decreased、fell、loss。
 - Said在正向新聞中高居頻率第一名，且出現次數顯著多於負向新聞。這可能反映當公司營運表現佳時，企業發言人傾向主動出面發表談話，強調正向訊號以增強市場信心，而當面臨虧損時，新聞多以客觀數據陳述為主，企業較少進行主動說明。



2.3 模型架構與訓練過程

1. 基準模型

- 採用 TF-IDF 進行向量化，搭配 Logistic Regression。
- 目的：TF-IDF 僅考量詞頻與關鍵字特徵，無法理解詞序與語境。以此作為基準，用以對比 BERT 在處理複雜語義時的表現。

2. 核心架構:

- 模型: bert-base-uncased。
- 分類層: 在 BERT 的向量輸出後，將 768 維特徵壓縮至 3 維輸出。
- 輸出: 透過 Softmax 函數將輸出轉換為 Negative、Neutral、Positive 三個類別的信心機率，以機率最高者作為最終情緒預測結果。

3. 訓練參數 (參考論文建議):

- Learning Rate: $2e-5$ 。(採用較低的學習率以避免破壞預訓練權重)
- Batch Size: 16。
- Epochs: 2。參考 BERT 原始論文建議，針對小型資料集進行 2 輪微調即可有效提取特徵，同時防止模型過度擬合 (Overfitting)。


2.4 評估結果與視覺化

1. 模型結果對比

- Baseline (TF-IDF + Logistic Regression): 準確率 71.44%
- BERT: 準確率 84.23%，較 Baseline 提升約 13%，顯示模型能更有效捕捉新聞標題中的語意與情緒線索。由於 BERT 展現出顯著的預測優勢，後續模型訓練與市場分析均採用此 BERT 模型進行預測。

2. 關鍵發現

- 混淆矩陣分析: 極性區分能力強：觀察混淆矩陣可發現，模型在判斷「正向」與「負向」時錯誤率極低，幾乎不會發生將壞消息誤判為好消息的錯誤。主要的預測誤差集中在「中立」類別與其他兩類的邊界。推測許多財經新聞僅陳述事實 (如: 營收成長 1%)，人類標註者有時也難以界定這屬於中立還是微幅正向。



- 不平衡資料處理: 雖然訓練資料中立情緒佔比較高，但經混淆矩陣驗證，模型在極性類別（正向與負向）的區分準確度高，並未出現偏袒大宗類別的預測偏誤。

3. 實際應用：Yahoo Finance 情緒與市場表現比較

3.1 實作流程

1. 資料蒐集與前處理

- 標的選擇: 選取 S&P 500 指數中權重最高的前 100 大成分股作為市場觀測標的，以確保情緒指標具備市場代表性。
- 利用 yfinance 針對每檔成分股採集近期新聞標題，初始獲取 2025/11/04 至 2025/12/24 期間共 812 則數據。
- 數據過濾: 經初步分析發現 11/04 至 12/15 期間數據較為稀疏，為確保數據密度，聚焦於新聞量最密集的 12/16 至 12/24 (有效樣本數 763 則) 進行分析。

2. 載入訓練好的 BERT 模型進行預測。

3. 情緒指標與 S&P 500 股價及日報酬比較


- 每日平均情緒: 計算當日所有新聞的情緒分數平均值，反映當天市場的即時情緒總和。
- 時間平移: 將情緒指標往前平移一天 (Shift +1 Day)，模擬真實交易情境，檢驗「昨日 (T-1) 的新聞情緒」是否能有效預測「今日 (T)」的股價走勢。

4. 統計量化檢定: 相關係數、p-value 觀察。

3.2 結果觀察

1. 情緒指標有效反映市場

- 數據顯示: 「當日情緒平均分數」與 S&P 500 股價點數呈正相關 ($r = 0.6115$)。
- 趨勢契合: 從圖表(A)可觀察到，情緒線與股價走勢相似。特別是在 12/17，模型捕捉到市場的負面情緒，當日指數亦觸及波段低點，這證明了 BERT 模型能準確識別市場情緒底點。



2. 領先指標的「反向預測」訊號

- 數據顯示: 昨日情緒與今日報酬率呈現負相關 ($r = -0.6104$)。
- 反向指標: 當昨日新聞情緒出現極度悲觀 (如 12/17) 時, 可能預示市場已過度反應, 進而引發次日的抄底反彈 (12/18 的正報酬)。
- 領先價值: 相較於當日情緒對報酬率的低相關性 ($r = -0.09$), 將新聞情緒時間往前平移一天的結果顯示, 新聞情緒對股價報酬率變動具備約 1 個交易日的滯後反應, 這賦予了情緒指標在極短線操作上的預警價值, 投資人可將昨日的極端情緒作為預測今日價格反轉依據。

3. 統計限制

- 受限於 12/16 以後之高密度樣本觀測時間較短 ($N=7$), 導致 p-value 未達傳統統計學的顯著門檻 (0.05)。然而, 相關係數絕對值達 0.6 以上, 以及結合視覺化的波段轉折對應, 在短期市場情緒監測與極端情緒辨識上, 具備實務參考價值。

4. 以下表格整理了 BERT 情緒指標與 S&P 500 市場表現的相關性檢定結果:

分析對象	相關係數	解釋
當日情緒 vs. 股價點數	0.6115	趨勢同步: 兩者呈現正相關, 顯示情緒能有效反映市場價格走勢。
昨日情緒 vs. 股價點數	0.2364	關聯轉弱: 價格點數對過去情緒的敏感度降低, 顯示點數主要受當下情緒影響。
當日情緒 vs. 日報酬率	0.0983	無顯著關聯: 日報酬受隨機雜訊干擾大, 當日情緒難以即時反映在百分比變動上。
昨日情緒 vs. 日報酬率	-0.6104	領先預警: 負相關顯示昨日極端情緒對今日報酬具備「反向預測」效力。

4. 參考資料

- BERT 原始論文: Devlin, J., et al. (2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*.
- kaggle 資料集:
<https://www.kaggle.com/datasets/ankurzing/sentiment-analysis-for-financial-news?resource=download>